Proyecto Econometría — Avance preliminar

Salarios de CEOs y desempeño de las empresas (`ceosal1`)

Universidad Técnica Federico Santa María · Ingeniería Comercial
Asignatura: Econometría ICS-294 · Semestre 2026-2
Profesor: Francisco Alfaro Medina
Entrega: 1ra entrega del Trabajo Práctico (avance preliminar) · 28 de octubre de 2026

Integrantes: Jorge Figueroa, Patrick Peñaloza, Joaquín Rubio, Felipe Hormachea, Felipe Vidal, Fernanda Nuñez.

Base de datos: `ceosal1`, paquete `wooldridge` de R
Pregunta de investigación: ¿se asocia el salario de los CEOs con el desempeño de sus empresas, una vez que se considera el tamaño de la firma y el sector en que opera?

Contenido del avance

Este documento cubre cada punto exigido para el avance preliminar en las instrucciones del trabajo:

Requisito del avance	Sección
Descripción de la base de datos, su origen y principales variables	1
Medidas de tendencia central y dispersión de las variables clave	2
Gráficos descriptivos de las variables más relevantes	3
Justificación de la variable dependiente y de las explicativas	4.2 y 4.3
Especificación del modelo de regresión poblacional	4.4
Planteamiento de las hipótesis de investigación	4.5

La estimación del modelo, la verificación de supuestos y el testeo de las hipótesis corresponden al informe final.

> **Para ejecutar en Google Colab:** el cuaderno usa R. Si Colab lo abre con Python, ir a *Entorno de ejecución → Cambiar tipo de entorno de ejecución → R* y luego *Ejecutar todas*.

In [1]:
```
# ============================================================
# 0. Dependencias
```

```r
# ============================================================

# Paquetes que usa el cuaderno:
#   - wooldridge: contiene la base ceosal1
#   - dplyr / tidyr: manipulación de datos
#   - ggplot2: gráficos
#   - corrplot: gráfico de la matriz de correlaciones
paquetes <- c("wooldridge", "dplyr", "tidyr", "ggplot2", "corrplot")

# Se instalan solo los paquetes que no estén disponibles
instalar <- paquetes[!(paquetes %in% installed.packages()[, "Package"])]
if (length(instalar)) install.packages(instalar)

# Se cargan todos los paquetes
invisible(lapply(paquetes, library, character.only = TRUE))

# Tamaño por defecto de los gráficos en el cuaderno
options(repr.plot.width = 9, repr.plot.height = 5)
```

```
Attaching package: ‘dplyr’


The following objects are masked from ‘package:stats’:

    filter, lag


The following objects are masked from ‘package:base’:

    intersect, setdiff, setequal, union


corrplot 0.92 loaded
```

1. Descripción de la base de datos

1.1 Origen y tipo de datos

La base `ceosal1` proviene del paquete `wooldridge` de R, que reúne los conjuntos de datos del libro *Introductory Econometrics: A Modern Approach* de Jeffrey M. Wooldridge. Según la documentación del paquete, Wooldridge construyó la base a partir de una **muestra aleatoria de los datos publicados en la edición del 6 de mayo de 1991 de la revista *Businessweek***, que informaba la remuneración de los máximos ejecutivos (CEOs) de grandes empresas de Estados Unidos.

- **Tipo de datos:** corte transversal (cada empresa se observa una sola vez).
- **Unidad de observación:** el CEO de una empresa estadounidense y su firma.
- **Período:** el salario y las ventas corresponden a 1990; las medidas de rentabilidad son promedios o variaciones del período 1988–1990.
- **Tamaño:** 209 observaciones y 12 variables.

En el libro la base se usa para estudiar cómo el salario del CEO responde al tamaño de la empresa (ventas) y a su rentabilidad (ROE), lo que coincide con el tema de este trabajo.

1.2 Diccionario de variables

Variable	Descripción	Unidad	Tipo
`salary`	Salario del CEO en 1990	miles de USD	Continua
`pcsalary`	Variación porcentual del salario entre 1989 y 1990	%	Continua
`sales`	Ventas de la empresa en 1990	millones de USD	Continua
`roe`	Rentabilidad sobre el patrimonio (*return on equity*), promedio 1988–1990	%	Continua
`pcroe`	Variación porcentual del ROE entre 1988 y 1990	%	Continua
`ros`	Rentabilidad de la acción de la empresa (*return on stock*), 1988–1990	%	Continua
`indus`	1 si la empresa es industrial	0/1	Dummy
`finance`	1 si la empresa es financiera	0/1	Dummy
`consprod`	1 si la empresa produce bienes de consumo	0/1	Dummy
`utility`	1 si la empresa es de servicios públicos o transporte	0/1	Dummy
`lsalary`	Logaritmo natural de `salary`	log	Continua
`lsales`	Logaritmo natural de `sales`	log	Continua

Las cuatro dummies de sector son mutuamente excluyentes: cada empresa pertenece a exactamente uno de los cuatro sectores (se verifica en la sección 1.3).

In [2]:
```r
# ============================================================
# 1. Carga de datos
# ============================================================

data("ceosal1")          # carga la base desde el paquete wooldridge
ceo <- ceosal1           # copia de trabajo

dim(ceo)                 # número de observaciones y de variables
str(ceo)                 # tipo de cada variable
head(ceo)                # primeras filas
```

```
'data.frame':   209 obs. of  12 variables:
 $ salary  : int  1095 1001 1122 578 1368 1145 1078 1094 1237 833 ...
 $ pcsalary: int  20 32 9 -9 7 5 10 7 16 5 ...
 $ sales   : num  27595 9958 6126 16246 21783 ...
 $ roe     : num  14.1 10.9 23.5 5.9 13.8 ...
 $ pcroe   : num  106.4 -30.6 -16.3 -25.7 -3 ...
 $ ros     : int  191 13 14 -21 56 55 62 44 37 37 ...
 $ indus   : int  1 1 1 1 1 1 1 1 1 1 ...
 $ finance : int  0 0 0 0 0 0 0 0 0 0 ...
 $ consprod: int  0 0 0 0 0 0 0 0 0 0 ...
 $ utility : int  0 0 0 0 0 0 0 0 0 0 ...
 $ lsalary : num  7 6.91 7.02 6.36 7.22 ...
 $ lsales  : num  10.23 9.21 8.72 9.7 9.99 ...
 - attr(*, "time.stamp")= chr "25 Jun 2011 23:03"
```

A data.frame: 6 × 12

	salary	pcsalary	sales	roe	pcroe	ros	indus	finance	consprod	utility
	<int>	<int>	<dbl>	<dbl>	<dbl>	<int>	<int>	<int>	<int>	<int>
1	1095	20	27595.0	14.1	106.4	191	1	0	0	0
2	1001	32	9958.0	10.9	-30.6	13	1	0	0	0
3	1122	9	6125.9	23.5	-16.3	14	1	0	0	0
4	578	-9	16246.0	5.9	-25.7	-21	1	0	0	0
5	1368	7	21783.2	13.8	-3.0	56	1	0	0	0
6	1145	5	6021.4	20.0	1.0	55	1	0	0	0

1.3 Revisión de datos nulos y consistencia

Antes del análisis se revisa si existen valores perdidos, si las dummies de sector clasifican a cada empresa en un único sector y si las variables en logaritmo coinciden con las variables originales.

In [3]:

```r
# Valores perdidos por columna y en total
colSums(is.na(ceo))
sum(is.na(ceo))

# Cada empresa debe pertenecer a un solo sector
# (la suma de las cuatro dummies debe ser 1)
table(ceo$indus + ceo$finance + ceo$consprod + ceo$utility)

# lsalary y lsales deben ser el logaritmo de salary y sales
all.equal(ceo$lsalary, log(ceo$salary), tolerance = 1e-4)
all.equal(ceo$lsales,  log(ceo$sales),  tolerance = 1e-4)

# Variable categórica de sector, útil para tablas y gráficos
ceo$sector <- factor(
  case_when(ceo$indus == 1    ~ "Industrial",
            ceo$finance == 1  ~ "Financiero",
            ceo$consprod == 1 ~ "Consumo",
            ceo$utility == 1  ~ "Utilities/transporte"),
  levels = c("Industrial", "Financiero", "Consumo",
             "Utilities/transporte"))
table(ceo$sector)
```

salary: 0 **pcsalary:** 0 **sales:** 0 **roe:** 0 **pcroe:** 0 **ros:** 0 **indus:** 0 **finance:** 0 **consprod:** 0 **utility:** 0 **lsalary:** 0 **lsales:** 0

```
0
   1
 209
TRUE
TRUE
           Industrial           Financiero              Consumo
                   67                   46                   60
 Utilities/transporte
                   36
```

La base no presenta valores perdidos, por lo que se trabaja con las 209 observaciones. Cada empresa pertenece a un solo sector y las variables `lsalary` y `lsales` corresponden efectivamente al logaritmo de `salary` y `sales`. La muestra se reparte entre empresas industriales (67), de bienes de consumo (60), financieras (46) y de servicios públicos o transporte (36).

2. Estadística descriptiva

2.1 Medidas de tendencia central y dispersión

Para cada variable continua se calculan:

- **Tendencia central:** media y mediana.
- **Dispersión:** desviación estándar (DE), coeficiente de variación (CV = DE/media), rango (mínimo y máximo) y rango intercuartílico (RIC = Q3 − Q1).
- **Forma:** asimetría (0 en una distribución simétrica; positiva si hay cola larga a la derecha) y curtosis (3 en una distribución normal; mayor a 3 indica colas pesadas o valores extremos).

In [4]:
```r
# ============================================================
# 2. Estadística descriptiva
# ============================================================

# Asimetría y curtosis calculadas con momentos muestrales
asimetria <- function(x) {
  m <- mean(x)
  mean((x - m)^3) / mean((x - m)^2)^(3/2)
}
curtosis <- function(x) {
  m <- mean(x)
  mean((x - m)^4) / mean((x - m)^2)^2
}

# Función que resume una variable numérica
resumen <- function(x) {
  c(Media     = mean(x),
    Mediana   = median(x),
    DE        = sd(x),
    CV        = sd(x) / mean(x),
    Min       = min(x),
    Q1        = unname(quantile(x, 0.25)),
```

```
    Q3        = unname(quantile(x, 0.75)),
    Max       = max(x),
    RIC       = IQR(x),
    Asimetria = asimetria(x),
    Curtosis  = curtosis(x))
}

vars_continuas <- c("salary", "lsalary", "sales", "lsales",
                    "roe", "ros", "pcsalary", "pcroe")

tabla_desc <- t(sapply(ceo[, vars_continuas], resumen))

# Tendencia central y dispersión
round(tabla_desc[, c("Media", "Mediana", "DE", "CV", "Min", "Max")], 3)

# Posición y forma de la distribución
round(tabla_desc[, c("Q1", "Q3", "RIC", "Asimetria", "Curtosis")], 3)
```

A matrix: 8 × 6 of type dbl

	Media	Mediana	DE	CV	Min	Max
salary	1281.120	1039.000	1372.345	1.071	223.000	14822.000
lsalary	6.950	6.946	0.566	0.081	5.407	9.604
sales	6923.793	3705.200	10633.271	1.536	175.200	97649.898
lsales	8.292	8.217	1.013	0.122	5.166	11.489
roe	17.184	15.500	8.519	0.496	0.500	56.300
ros	61.804	52.000	68.177	1.103	-58.000	418.000
pcsalary	13.282	9.000	32.634	2.457	-61.000	212.000
pcroe	10.800	-3.000	97.219	9.001	-98.900	977.000

A matrix: 8 × 5 of type dbl

	Q1	Q3	RIC	Asimetria	Curtosis
salary	736.000	1407.000	671.000	6.855	60.541
lsalary	6.601	7.249	0.648	0.880	6.268
sales	2210.300	7177.000	4966.700	4.999	35.300
lsales	7.701	8.879	1.178	0.094	3.755
roe	12.400	20.000	7.600	1.561	6.679
ros	21.000	81.000	60.000	2.080	9.400
pcsalary	-1.000	20.000	21.000	2.734	15.282
pcroe	-21.200	19.500	40.700	6.417	56.099

Interpretación de las variables clave

- **Salario (`salary`).** El salario medio es de 1 281 miles de dólares (USD 1,28 millones), pero la mediana es menor, 1 039 miles: la mitad de los CEOs gana menos de USD 1,04 millones. La desviación estándar (1 372) supera a la media (CV = 1,07), y el rango va de 223 a 14 822 miles de dólares. La asimetría (6,9) y

la curtosis (≈61) son muy altas: unos pocos CEOs con remuneraciones excepcionales alejan la media de la mediana.

- **Logaritmo del salario (`lsalary`).** Al aplicar logaritmo la media (6,95) y la mediana (6,95) prácticamente coinciden, el CV baja a 0,08 y la asimetría se reduce a 0,88. La transformación logarítmica vuelve la distribución mucho más simétrica, lo que respalda usar `lsalary` como variable dependiente (sección 4.2).
- **Ventas (`sales`).** Las empresas son grandes y muy heterogéneas: las ventas medias son USD 6 924 millones, la mediana USD 3 705 millones, y el rango va de USD 175 millones a casi USD 97 650 millones (CV = 1,54; asimetría 5,0). En logaritmo (`lsales`) la asimetría es prácticamente nula (0,09).
- **Rentabilidad sobre el patrimonio (`roe`).** El ROE promedio de 1988–1990 es 17,2 % y la mediana 15,5 %. La DE es 8,5 puntos porcentuales (CV = 0,50) y el rango va de 0,5 % a 56,3 %. Todas las empresas tuvieron ROE positivo, con una cola moderada hacia la derecha (asimetría 1,56).
- **Rentabilidad de la acción (`ros`).** La rentabilidad bursátil acumulada promedio es 61,8 % (mediana 52 %), con una dispersión muy alta: va de −58 % a 418 % (DE = 68,2). 23 empresas tuvieron rentabilidad bursátil negativa en el período.
- **Variaciones porcentuales (`pcsalary` , `pcroe`).** Ambas son muy dispersas; en particular `pcroe` tiene un CV de 9 y un máximo de 977 %, producto de empresas que partían de un ROE cercano a cero. Por esta razón no se usan como variables explicativas (sección 4.3).

2.2 Variables binarias: composición por sector

En las variables dummy la media corresponde a la proporción de empresas que pertenecen a cada sector. Además, se comparan las variables clave entre sectores.

In [5]:
```r
# Proporción de empresas en cada sector
dummies <- c("indus", "finance", "consprod", "utility")
round(sapply(ceo[, dummies], mean), 3)

# Salario del CEO por sector
ceo %>%
  group_by(sector) %>%
  summarise(n               = n(),
            salario_medio   = mean(salary),
            salario_mediana = median(salary),
            lsalary_medio   = mean(lsalary)) %>%
  mutate(across(where(is.numeric), ~ round(.x, 2)))

# Tamaño y rentabilidad promedio de las empresas por sector
ceo %>%
  group_by(sector) %>%
  summarise(ventas_medias = mean(sales),
            roe_medio     = mean(roe),
            ros_medio     = mean(ros)) %>%
  mutate(across(where(is.numeric), ~ round(.x, 2)))
```

indus: 0.321 **finance:** 0.22 **consprod:** 0.287 **utility:** 0.172

A tibble: 4 × 5

sector	n	salario_medio	salario_mediana	lsalary_medio
<fct>	<dbl>	<dbl>	<dbl>	<dbl>
Industrial	67	1139.34	1041.0	6.94
Financiero	46	1344.91	1119.5	7.06
Consumo	60	1722.42	1246.0	7.15
Utilities/transporte	36	727.97	646.0	6.51

A tibble: 4 × 4

sector	ventas_medias	roe_medio	ros_medio
<fct>	<dbl>	<dbl>	<dbl>
Industrial	8369.39	17.35	41.06
Financiero	5844.05	14.33	47.98
Consumo	8080.15	22.66	99.08
Utilities/transporte	3685.80	11.41	55.94

El 32,1 % de las empresas es industrial, el 28,7 % produce bienes de consumo, el 22,0 % es financiera y el 17,2 % pertenece a servicios públicos o transporte.

Las diferencias entre sectores son marcadas. Los CEOs de empresas de **bienes de consumo** tienen el salario medio más alto (1 722 miles de dólares) y esas empresas también muestran la mayor rentabilidad (ROE medio 22,7 %, rentabilidad bursátil media 99 %). En el otro extremo, los CEOs de **servicios públicos y transporte** ganan en promedio 728 miles de dólares, poco más de la mitad que el resto, y sus empresas son las de menor ventas y menor ROE. Esto sugiere que el sector debe incluirse en el modelo: si se omitiera, parte de las diferencias de salario entre sectores se atribuiría erróneamente al desempeño o al tamaño.

2.3 Correlaciones

La matriz de correlaciones muestra la asociación lineal simple entre pares de variables. Se usan las variables en la forma en que entrarán al modelo (salario y ventas en logaritmo).

In [6]:
```r
# Matriz de correlaciones de las variables del modelo
vars_modelo <- ceo[, c("lsalary", "lsales", "roe", "ros",
                       "finance", "consprod", "utility")]
round(cor(vars_modelo), 3)

# Pruebas de significancia de la correlación con lsalary
p_valores <- sapply(c("lsales", "roe", "ros"),
                    function(v) cor.test(ceo$lsalary, ceo[[v]])$p.value)
signif(p_valores, 3)

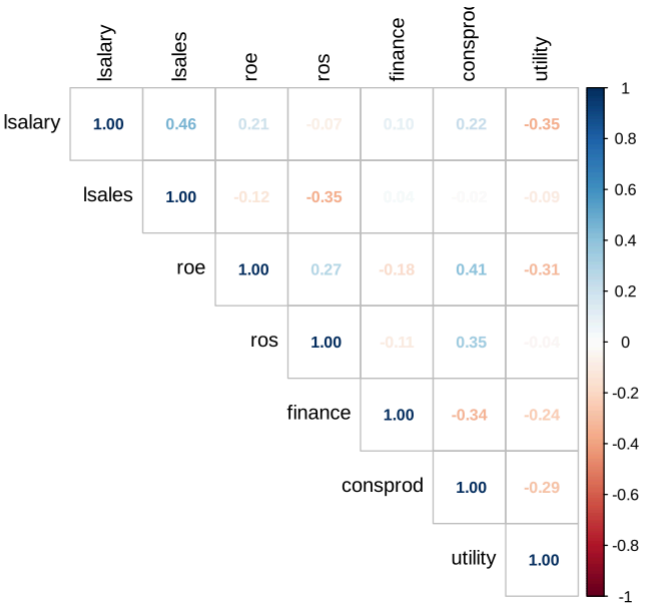
# Visualización
```

```
corrplot(cor(vars_modelo), method = "number", type = "upper",
         tl.col = "black", number.cex = 0.8)
```

A matrix: 7 × 7 of type dbl

	lsalary	lsales	roe	ros	finance	consprod	utility
lsalary	1.000	0.459	0.208	-0.075	0.101	0.220	-0.355
lsales	0.459	1.000	-0.123	-0.350	0.039	-0.019	-0.094
roe	0.208	-0.123	1.000	0.275	-0.179	0.409	-0.310
ros	-0.075	-0.350	0.275	1.000	-0.108	0.348	-0.039
finance	0.101	0.039	-0.179	-0.108	1.000	-0.337	-0.242
consprod	0.220	-0.019	0.409	0.348	-0.337	1.000	-0.289
utility	-0.355	-0.094	-0.310	-0.039	-0.242	-0.289	1.000

lsales: 2.7e-12 **roe:** 0.00245 **ros:** 0.283



Interpretación de las correlaciones

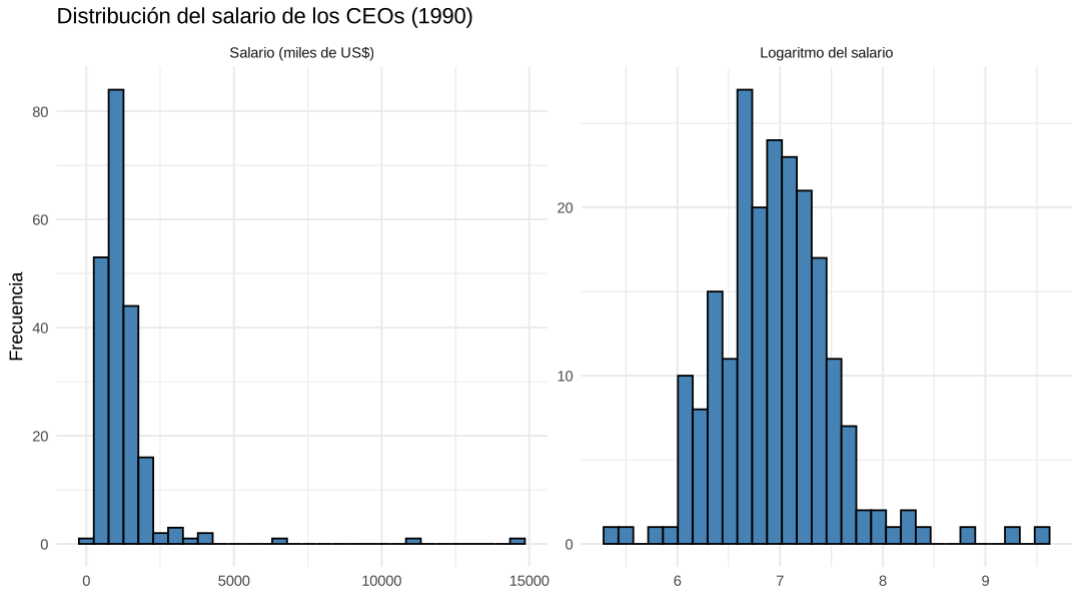
- **`lsalary` y `lsales` (0,46):** es la correlación más fuerte con el salario y es estadísticamente significativa (p < 0,001). Las empresas más grandes pagan más a sus CEOs.
- **`lsalary` y `roe` (0,21):** correlación positiva, débil pero significativa al 1 % (p ≈ 0,002). Las empresas más rentables tienden a pagar salarios más altos.
- **`lsalary` y `ros` (−0,08):** prácticamente nula y no significativa (p ≈ 0,28). A primera vista, el desempeño bursátil no se asocia con el salario.
- **`lsalary` y `utility` (−0,36):** confirma que los CEOs de servicios públicos ganan menos; `consprod` se asocia positivamente (0,22).
- **Entre explicativas:** `roe` y `ros` se correlacionan positivamente (0,28), igual que `roe` y `consprod` (0,41); `lsales` y `ros` tienen correlación negativa (−0,35). Ninguna correlación entre explicativas supera 0,5, por lo que no se anticipan problemas graves de multicolinealidad; esto se evaluará con el VIF en el informe final.

Estas correlaciones son relaciones simples, no efectos *ceteris paribus*. Por ejemplo, las empresas de bienes de consumo son a la vez más rentables y pagan más, de modo que parte de la correlación entre `roe` y salario podría deberse al sector. El modelo de regresión múltiple permite separar estos factores.

3. Gráficos descriptivos

3.1 Distribución del salario: niveles y logaritmo

In [7]:
```
# Histogramas del salario en niveles y en logaritmo, uno al lado del otro
ceo %>%
  select(salary, lsalary) %>%
  pivot_longer(everything(),
               names_to = "variable", values_to = "valor") %>%
  mutate(variable = recode(variable,
                           salary  = "Salario (miles de US$)",
                           lsalary = "Logaritmo del salario"),
         variable = factor(variable,
                           levels = c("Salario (miles de US$)",
                                      "Logaritmo del salario"))) %>%
  ggplot(aes(x = valor)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "black") +
  facet_wrap(~ variable, scales = "free") +
  labs(title = "Distribución del salario de los CEOs (1990)",
       x = NULL, y = "Frecuencia") +
  theme_minimal()
```

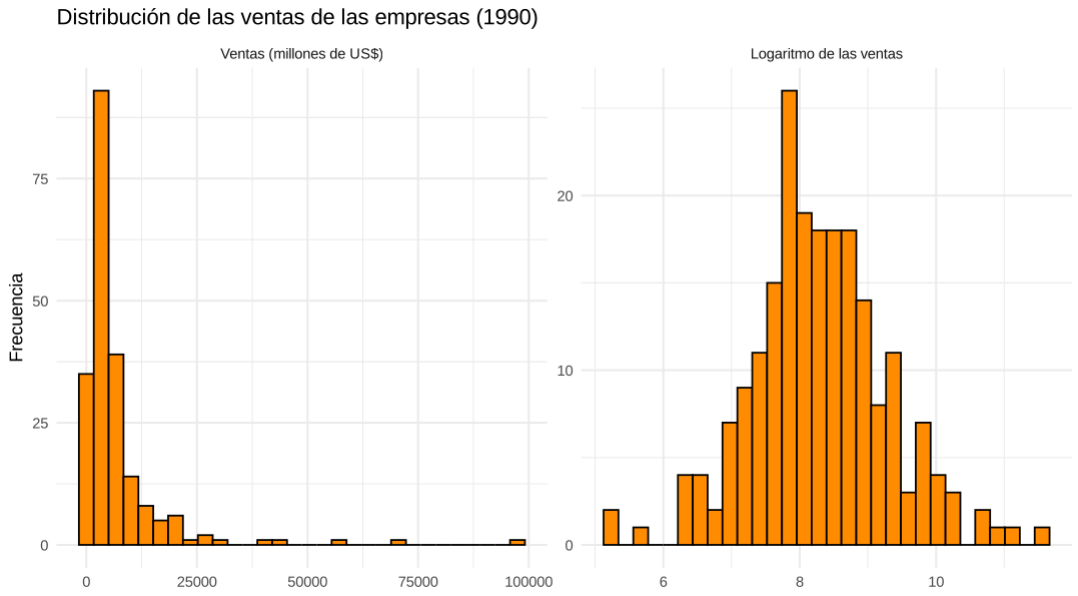


En niveles, el salario se concentra bajo los 2 000 miles de dólares y presenta una cola larga a la derecha, con dos CEOs que superan los 10 000 miles de dólares. En logaritmo la distribución es aproximadamente simétrica y de forma acampanada. Esta es la principal razón para modelar `lsalary` en vez de `salary`.

3.2 Distribución de las ventas: niveles y logaritmo

In [8]:
```
ceo %>%
  select(sales, lsales) %>%
```

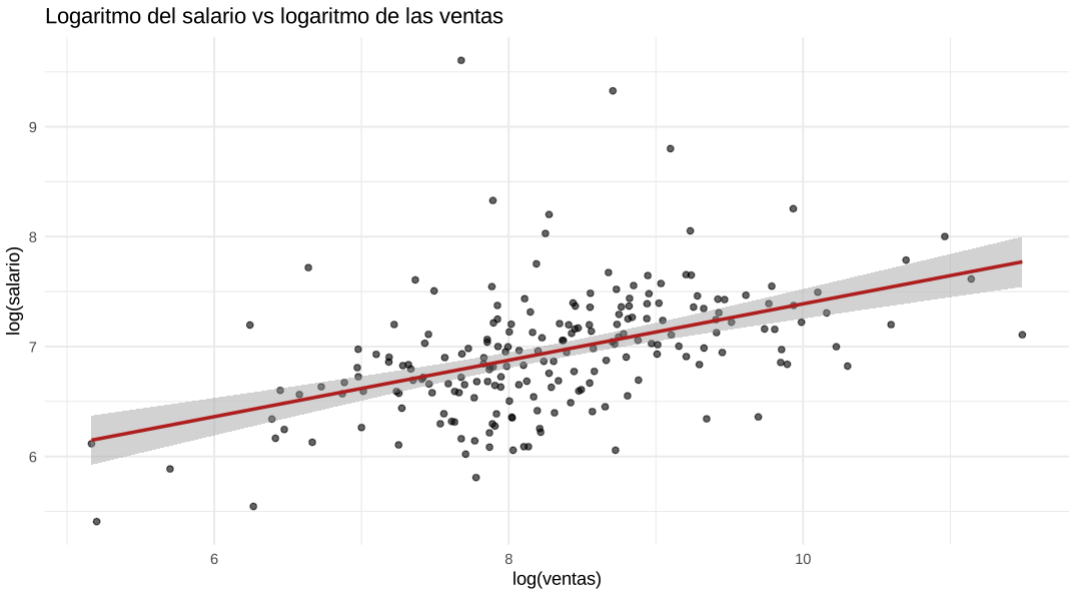
```
  pivot_longer(everything(),
               names_to = "variable", values_to = "valor") %>%
  mutate(variable = recode(variable,
                           sales  = "Ventas (millones de US$)",
                           lsales = "Logaritmo de las ventas"),
         variable = factor(variable,
                           levels = c("Ventas (millones de US$)",
                                      "Logaritmo de las ventas"))) %>%
  ggplot(aes(x = valor)) +
  geom_histogram(bins = 30, fill = "darkorange", color = "black") +
  facet_wrap(~ variable, scales = "free") +
  labs(title = "Distribución de las ventas de las empresas (1990)",
       x = NULL, y = "Frecuencia") +
  theme_minimal()
```



Las ventas tienen una asimetría aún más fuerte que el salario: la mayoría de las empresas vende menos de USD 10 000 millones, pero algunas superan los USD 50 000 millones. En logaritmo la distribución es casi simétrica, por lo que el tamaño de la empresa se incorpora como `lsales`.

3.3 Salario y tamaño de la empresa

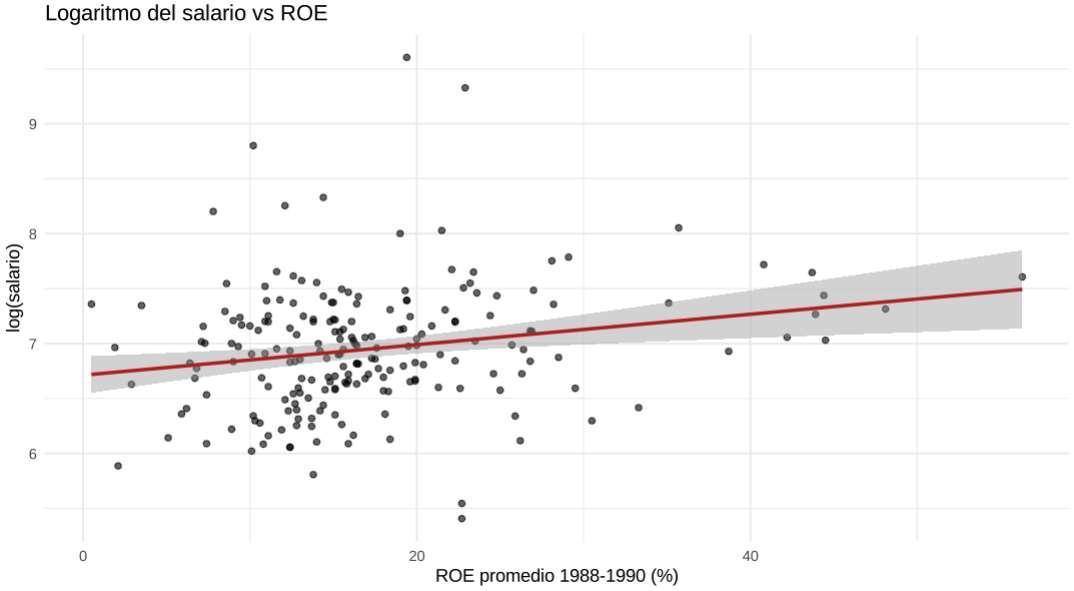
In [9]:
```
ggplot(ceo, aes(x = lsales, y = lsalary)) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "lm", formula = y ~ x, se = TRUE,
              color = "firebrick") +
  labs(title = "Logaritmo del salario vs logaritmo de las ventas",
       x = "log(ventas)", y = "log(salario)") +
  theme_minimal()
```



Se observa una relación positiva y aproximadamente lineal entre `lsales` y `lsalary`: las empresas más grandes pagan salarios más altos. Como ambas variables están en logaritmo, la pendiente de esta relación se interpreta como una **elasticidad**, lo que justifica la forma funcional log-log para el tamaño.

3.4 Salario y desempeño contable (ROE)

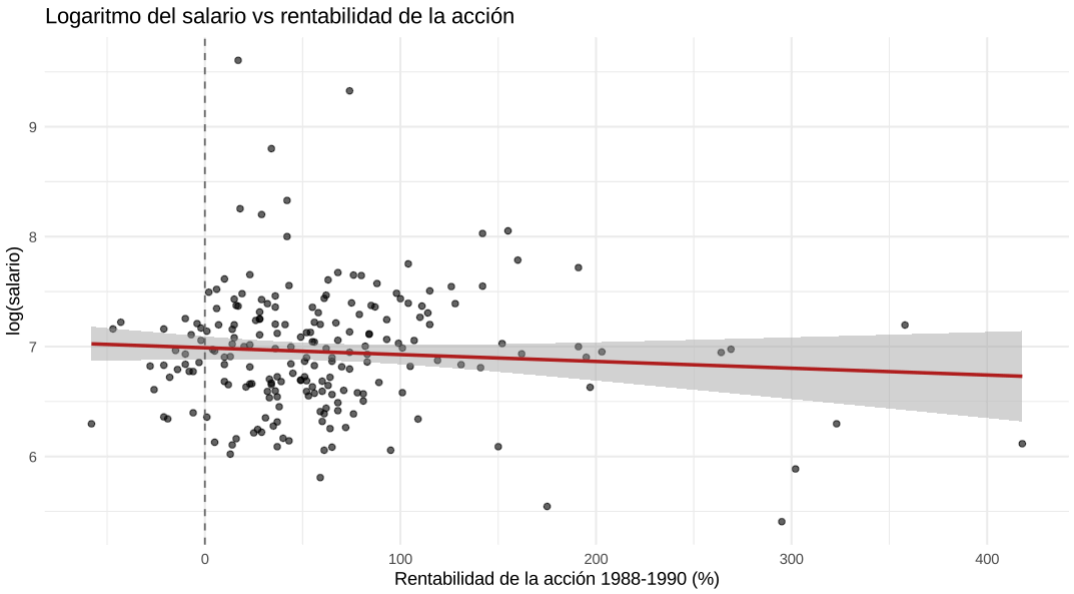
In [10]:
```
ggplot(ceo, aes(x = roe, y = lsalary)) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "lm", formula = y ~ x, se = TRUE,
              color = "firebrick") +
  labs(title = "Logaritmo del salario vs ROE",
       x = "ROE promedio 1988-1990 (%)", y = "log(salario)") +
  theme_minimal()
```



La relación entre ROE y salario es positiva pero con mucha dispersión alrededor de la recta, coherente con la correlación de 0,21. La mayoría de las empresas tiene un ROE entre 10 % y 25 %.

3.5 Salario y desempeño bursátil (rentabilidad de la acción)

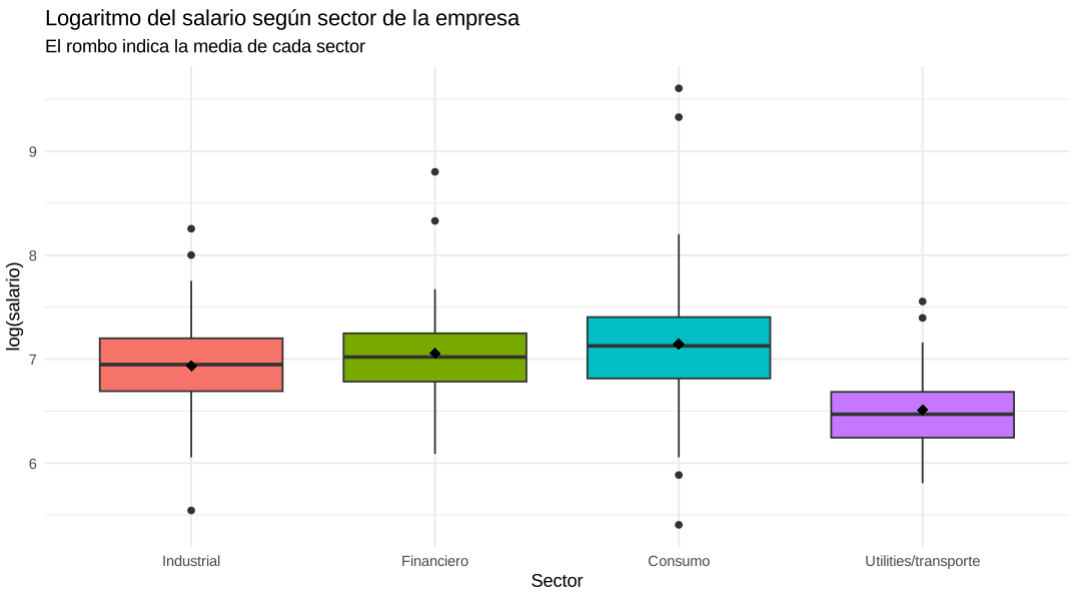
In [11]:
```
ggplot(ceo, aes(x = ros, y = lsalary)) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "lm", formula = y ~ x, se = TRUE,
              color = "firebrick") +
  geom_vline(xintercept = 0, linetype = "dashed", color = "grey40") +
  labs(title = "Logaritmo del salario vs rentabilidad de la acción",
       x = "Rentabilidad de la acción 1988-1990 (%)",
       y = "log(salario)") +
  theme_minimal()
```



La recta es prácticamente plana: en la relación simple, el salario no parece responder a la rentabilidad bursátil. Hay empresas con rentabilidad negativa (a la izquierda de la línea punteada) y algunas con rentabilidades sobre 200 %. El modelo múltiple permitirá ver si esta ausencia de relación se mantiene al controlar por tamaño y sector.

3.6 Salario según sector

In [12]:
```
ggplot(ceo, aes(x = sector, y = lsalary, fill = sector)) +
  geom_boxplot(show.legend = FALSE) +
  stat_summary(fun = mean, geom = "point", shape = 18, size = 3,
               show.legend = FALSE) +
  labs(title = "Logaritmo del salario según sector de la empresa",
       subtitle = "El rombo indica la media de cada sector",
       x = "Sector", y = "log(salario)") +
  theme_minimal()
```



Las cajas de los sectores industrial, financiero y de consumo se ubican en niveles similares, con el sector consumo ligeramente más alto. La caja de servicios públicos y transporte está claramente más abajo: su mediana es menor que el primer cuartil de los demás sectores. Esta diferencia motiva incluir las dummies de sector y plantear una hipótesis específica sobre las empresas reguladas (sección 4.5).

3.7 Valores atípicos

In [13]:
```
# Las cinco remuneraciones más altas de la muestra
top5 <- ceo[order(-ceo$salary),
            c("salary", "sales", "roe", "ros", "sector")]
head(top5, 5)

# Número de observaciones fuera de 1,5 RIC en cada variable
fuera_ric <- function(x) {
  q <- quantile(x, c(0.25, 0.75)); r <- IQR(x)
  sum(x < q[1] - 1.5 * r | x > q[2] + 1.5 * r)
}
sapply(ceo[, c("salary", "lsalary", "sales", "lsales", "roe", "ros")],
       fuera_ric)
```

A data.frame: 5 × 5

	salary	sales	roe	ros	sector
	<int>	<dbl>	<dbl>	<int>	<fct>
174	14822	2159.2	19.4	17	Consumo
164	11233	6047.9	22.9	74	Consumo
108	6640	8946.0	10.2	34	Financiero
87	4143	2678.4	14.4	42	Financiero
28	3844	20604.0	12.1	18	Industrial

salary: 9 **lsalary:** 7 **sales:** 21 **lsales:** 7 **roe:** 13 **ros:** 13

El salario más alto (14 822 miles de dólares) corresponde a una empresa de bienes de consumo con ventas relativamente bajas (USD 2 159 millones), y es más de 14 veces la mediana. En niveles, 9 salarios y 21 valores de ventas quedan fuera del rango de 1,5 RIC; en logaritmo la cantidad baja a 7 en ambas variables. Se trata de datos reales, no de errores, por lo que se mantienen en la muestra; usar logaritmos reduce su influencia en la estimación.

4. Planteamiento del modelo e hipótesis de investigación

4.1 Pregunta de investigación

La teoría de agencia plantea que los accionistas (el principal) no pueden observar directamente el esfuerzo del CEO (el agente), por lo que conviene vincular su remuneración con resultados observables de la empresa para alinear incentivos (Jensen y Murphy, 1990). Al mismo tiempo, la literatura muestra que el principal determinante del salario de los ejecutivos es el **tamaño de la empresa**: firmas más grandes requieren y atraen a ejecutivos más capaces y les pagan más (Rosen, 1982; Gabaix y Landier, 2008).

Este trabajo busca responder: **¿se asocia el salario del CEO con el desempeño de su empresa, medido por la rentabilidad contable (ROE) y por la rentabilidad bursátil, manteniendo constante el tamaño de la firma y su sector?**

4.2 Variable dependiente

Se utiliza `lsalary`, el logaritmo natural del salario del CEO en 1990, por tres razones:

1. **Es la variable que mide el fenómeno de interés**: la remuneración del CEO.
2. **Distribución:** `salary` tiene asimetría 6,9 y valores extremos (sección 2.1 y gráfico 3.1). En logaritmo la asimetría baja a 0,88 y media y mediana coinciden, lo que reduce la influencia de los valores atípicos.
3. **Interpretación:** con el salario en logaritmo, los coeficientes se leen como cambios porcentuales, más comparables entre CEOs que ganan montos muy distintos. Es la especificación usual en la literatura de remuneración de ejecutivos y la que usa Wooldridge con esta base.

4.3 Variables explicativas

Variable	Rol	Justificación
`lsales`	Tamaño de la empresa	Las empresas grandes pagan más (Rosen, 1982; Gabaix y Landier, 2008). Es la variable más correlacionada con el salario (0,46). En logaritmo su coeficiente es una elasticidad y se corrige la fuerte asimetría de `sales`.

Variable	Rol	Justificación
`roe`	Desempeño contable (variable de interés)	Mide la rentabilidad que la empresa genera para sus accionistas. Si la remuneración premia el desempeño, debería asociarse positivamente con el salario.
`ros`	Desempeño bursátil (variable de interés)	Mide el retorno que obtuvieron los accionistas en el mercado. Según la teoría de agencia, es la medida de desempeño más directamente ligada a la riqueza de los accionistas (Jensen y Murphy, 1990).
`finance`, `consprod`, `utility`	Controles de sector	El salario medio difiere fuertemente entre sectores (sección 2.2). Las empresas de servicios públicos están reguladas, lo que limita sus remuneraciones (Joskow, Rose y Shepard, 1993). Se omite `indus` para evitar multicolinealidad perfecta: el sector **industrial** es la categoría base.

Variables no incluidas:

- `salary` y `sales` en niveles: se reemplazan por sus logaritmos por las razones anteriores.
- `pcsalary`: es la variación del propio salario, por lo que no explica el nivel del salario sino que deriva de él.
- `pcroe`: mide el cambio en el ROE y no su nivel; además tiene valores extremos (hasta 977 %) generados por empresas que partían de un ROE cercano a cero.

4.4 Modelo de regresión poblacional

Se propone el siguiente Modelo de Regresión Lineal Múltiple:

$$\begin{aligned}\log(salary_i) = \beta_0 + \beta_1 \log(sales_i) + \beta_2\, roe_i + \beta_3\, ros_i \\ + \beta_4\, finance_i + \beta_5\, consprod_i + \beta_6\, utility_i + u_i\end{aligned}$$

donde $i = 1, \ldots, 209$ indexa a los CEOs y u_i es el término de error, que recoge los factores no observados que afectan el salario (por ejemplo, la experiencia o la antigüedad del CEO).

Interpretación de los parámetros y signo esperado

Parámetro	Interpretación (*ceteris paribus*)	Signo esperado
β_1	Elasticidad salario–ventas: un aumento de 1 % en las ventas se asocia con un cambio de β_1 % en el salario.	$+$ (entre 0 y 1)
β_2	Un punto porcentual más de ROE se asocia con un cambio de aproximadamente $100 \cdot \beta_2$ % en el salario.	$+$
β_3	Un punto porcentual más de rentabilidad de la acción se asocia con un cambio de aproximadamente $100 \cdot \beta_3$ % en el salario.	$+$
β_4	Diferencia porcentual aproximada del salario de un CEO financiero respecto de uno industrial.	$\pm$

Parámetro	Interpretación (*ceteris paribus*)	Signo esperado
β_5	Diferencia porcentual aproximada del salario de un CEO de bienes de consumo respecto de uno industrial.	$+$
β_6	Diferencia porcentual aproximada del salario de un CEO de servicios públicos o transporte respecto de uno industrial.	$-$

Se espera que β_1 sea menor que 1 porque el salario crece con el tamaño de la empresa, pero menos que proporcionalmente.

4.5 Hipótesis de investigación

Las hipótesis se plantean sobre los parámetros del modelo poblacional, se contrastarán con el modelo estimado (y corregido, si corresponde) en el informe final y se evaluarán con un nivel de significancia del 5 %.

H1 — Tamaño: a mayor tamaño de la empresa, mayor es el salario del CEO.

$$H_0 : \beta_1 = 0 \quad \text{vs.} \quad H_1 : \beta_1 > 0$$

H2 — Desempeño contable: un mayor ROE se asocia con un mayor salario del CEO, manteniendo constantes el tamaño, la rentabilidad bursátil y el sector.

$$H_0 : \beta_2 = 0 \quad \text{vs.} \quad H_1 : \beta_2 > 0$$

H3 — Desempeño bursátil: una mayor rentabilidad de la acción se asocia con un mayor salario del CEO, manteniendo constantes el tamaño, el ROE y el sector.

$$H_0 : \beta_3 = 0 \quad \text{vs.} \quad H_1 : \beta_3 > 0$$

H4 — Desempeño en conjunto: las medidas de desempeño, en conjunto, ayudan a explicar el salario del CEO (prueba F de significancia conjunta).

$$H_0 : \beta_2 = \beta_3 = 0 \quad \text{vs.} \quad H_1 : \text{al menos uno de } \beta_2, \beta_3 \text{ es distinto de } 0$$

H5 — Sector regulado: los CEOs de empresas de servicios públicos y transporte ganan menos que los de empresas industriales de igual tamaño y desempeño.

$$H_0 : \beta_6 = 0 \quad \text{vs.} \quad H_1 : \beta_6 < 0$$

H1 a H3 y H5 se contrastarán con pruebas *t* de una cola y H4 con una prueba *F*. Las hipótesis H2 a H4 responden directamente a la pregunta de investigación; H1 y H5 verifican que el modelo recoja los determinantes conocidos del salario de los ejecutivos.

4.6 Próximos pasos (informe final)

1. Estimar el modelo por MCO e interpretar el signo, la magnitud y la significancia de los coeficientes, junto con el R^2.
2. Verificar los supuestos: exogeneidad (por ejemplo, la posible omisión de la habilidad o la antigüedad del CEO), homocedasticidad (Breusch-Pagan y

White), normalidad de los errores y multicolinealidad (VIF).
3. Aplicar correcciones si se detectan problemas (por ejemplo, errores estándar robustos).
4. Contrastar las hipótesis H1 a H5 con el modelo corregido y redactar las conclusiones.

Referencias

- Gabaix, X. y Landier, A. (2008). Why has CEO pay increased so much? *The Quarterly Journal of Economics, 123*(1), 49–100.
- Jensen, M. C. y Murphy, K. J. (1990). Performance pay and top-management incentives. *Journal of Political Economy, 98*(2), 225–264.
- Joskow, P., Rose, N. y Shepard, A. (1993). Regulatory constraints on CEO compensation. *Brookings Papers on Economic Activity: Microeconomics, 1993*(1), 1–72.
- R Core Team (2024). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing.
- Rosen, S. (1982). Authority, control, and the distribution of earnings. *The Bell Journal of Economics, 13*(2), 311–323.
- Shea, J. M. (2024). *wooldridge: 115 data sets from "Introductory Econometrics: A Modern Approach"* (versión 1.4) [paquete de R].
- Wooldridge, J. M. (2020). *Introductory Econometrics: A Modern Approach* (7.ª ed.). Cengage Learning.